





What is NLP?

Natural Language Processing คืออะไร?



“NLP คือเทคนิคที่ช่วยทำให้งานที่เกี่ยวข้องกับภาษาเป็นไปโดยอัตโนมัติ”

ให้คอมพิวเตอร์สามารถทำงานที่มนุษย์ทำเกี่ยวกับภาษาได้แทนเรา

ครอบคลุมงานด้านภาษาหลัก ๆ ของมนุษย์



การฟัง

คอมพิวเตอร์เข้าใจ
เสียงพูดของมนุษย์



การพูด

คอมพิวเตอร์พูดหรือ
ตอบสนองด้วยภาษาธรรมชาติ



การอ่าน

คอมพิวเตอร์อ่านและดึง
ข้อมูลจากข้อความ



การเขียน


คอมพิวเตอร์สร้างข้อความ
หรือสรุปเนื้อหา



การเข้าใจภาษา

คอมพิวเตอร์เข้าใจความหมาย
บริบท และเจตนาของภาษา

NLP เกิดจากการผสมผสานหลายศาสตร์



ความเข้าใจภาษา (Linguistics)



การเขียนโปรแกรม (Programming)



วิทยาการคอมพิวเตอร์ (Computer Science)



ความเข้าใจภาษา (Linguistics)

+



การเขียนโปรแกรม (Programming)

+



วิทยาการคอมพิวเตอร์ (Computer Science)



Natural Language Processing (NLP)

ศาสตร์ที่ทำให้คอมพิวเตอร์เข้าใจและประมวลผลภาษาของมนุษย์
ได้อย่างมีความหมาย



Applications of NLP

NLP ถูกนำไปใช้ทำอะไรบ้าง?

หลังจากเข้าใจว่า NLP คืออะไร คำถามถัดไปคือ ปัจจุบันมีการนำ NLP ไปใช้ในงานอะไรบ้าง โดยสามารถแบ่งออกเป็น **2 กลุ่มใหญ่ ๆ** ดังนี้

1 Text Analytics

การวิเคราะห์ข้อความจำนวนมาก ๆ เพื่อค้นหา Insight หรือความรู้ใหม่ ๆ ที่เรายังไม่เคยรู้มาก่อน




เป้าหมาย

ค้นหาแนวโน้ม ความคิดเห็น หัวข้อสำคัญ และความสัมพันธ์ จากข้อมูลข้อความ

2

ผลิตภัณฑ์ปัญญาประดิษฐ์ (AI Products)

สร้างผลิตภัณฑ์หรือแอปที่ช่วย **automate** งานด้านภาษาต่าง ๆ ให้กับเรา
สื่อสารโต้ตอบและช่วยทำงานแทนมนุษย์



เป้าหมาย

ทำให้คอมพิวเตอร์เข้าใจภาษา
โต้ตอบกับเรา และทำงานด้านภาษา
ได้อย่างชาญฉลาด



Sentiment Analysis

Understand Emotions. Drive Better Decisions.

AI-powered sentiment analysis captures and classifies emotions from social media conversations in real time.




Positive
20.7%



Neutral
78.3%



Negative
1.0%



สรุปใจความสำคัญจากข้อมูลจำนวนมาก ให้เข้าใจง่ายในภาพเดียว



ให้เครื่องช่วยสรุป

ขนาดคำ = ความถี่

เข้าใจสาระได้เร็วขึ้น

ตัวอย่างนี้บอกอะไรเรา?

6



Topic Modeling

จัดกลุ่มข้อมูลจำนวนมาก
ให้เข้าใจง่ายในปริบทา

Topic Modeling ช่วยแบ่งข้อความจำนวนมาก
ออกเป็นกลุ่มย่อย (Topics) ตามความหมาย
ที่คล้ายกัน เพื่อให้เห็นภาพรวมของเนื้อหา
และเข้าใจประเด็นสำคัญได้รวดเร็ว



ประหยัดเวลา
ไม่ต้องอ่านทุกเอกสาร



โฟกัสเฉพาะเรื่องที่น่าสนใจ
เข้าใจเชิงลึกได้ง่าย



เพิ่มประสิทธิภาพการวิเคราะห์
และการตัดสินใจ

เอกสารชุดเดียวกัน แบ่งออกเป็น 6 กลุ่ม (6 Topics)



1. เศรษฐกิจ

สร้าง
พัฒนา
พัฒนา
พัชฉ
การประชุม
เกษตรกร
สุขภาพ
ส่งเสริม
การพัฒนา
บริการ



2. นักการเมือง

นายกรัฐมนตรี
คณะกรรมการ
ประชาชน
รัฐมนตรี
พระ
กระทรวง
หน่วยงาน
ว่าการ
คณะรัฐมนตรี
รัฐบาล



3. นโยบาย / รัฐบาล

เสนอ
สนับสนุน
ตรวจ
ดูแล
ดำเนินการ
ดำเนินดำเนินการ
ขับเคลื่อน
โรค
ติดตาม
ทำเนียบรัฐบาล



4. โรงพยาบาล / สาธารณสุข

ศูนย์
โรงพยาบาล
พื้นที่
งาน
ประเทศ
จังหวัด
เขต



5. สื่อ / ข่าว / ประชาสัมพันธ์

ข้อมูล
พิมพ์
บาท
ระบบ
ไทย
ตลาด
ลด
คน
ล้าน
ตุลาคม



6. แผนงาน / นโยบาย

สำนักงาน
แผน
มาตรการ
ข่าว
ผลกระทบ
โครงการ
แรงงาน
สถานการณ์
นโยบาย
สินค้า



เลือกดูเฉพาะ Topic ที่สนใจ เจาะลึกได้ตรงจุด ตัดสินใจได้แม่นยำ



Overall

6,505



Facebook

406



Twitter

4,501



Instagram

1,507



YouTube

91

Overview

Keyword & Hashtag

Top Mentions

Geolocation

Focus Feed

Languages

Time

Sentiment


Questions

Type of Mentions

Expand

Mentions Console

Data Timeline





NLP + Text Analytics
allow us to **understand**
a large amount of text
without reading it all.



Applications of NLP

NLP ถูกนำไปใช้ทำอะไรบ้าง?

หลังจากเข้าใจว่า NLP คืออะไร คำถามถัดไปคือ ปัจจุบันมีการนำ NLP ไปใช้ในงานอะไรบ้าง โดยสามารถแบ่งออกเป็น **2 กลุ่มใหญ่ ๆ** ดังนี้

1 Text Analytics

การวิเคราะห์ข้อความจำนวนมาก ๆ เพื่อค้นหา Insight หรือความรู้ใหม่ ๆ ที่เรายังไม่เคยรู้มาก่อน



เป้าหมาย

ค้นหาแนวโน้ม ความคิดเห็น
หัวข้อสำคัญ และความสัมพันธ์
จากข้อมูลข้อความ

2

ผลิตภัณฑ์ปัญญาประดิษฐ์ (AI Products)

สร้างผลิตภัณฑ์หรือแอปที่ช่วย **automate**
งานด้านภาษาต่าง ๆ ให้กับเรา
สื่อสารโต้ตอบและช่วยทำงานแทนมนุษย์




เป้าหมาย

ทำให้คอมพิวเตอร์เข้าใจภาษา
โต้ตอบกับเรา และทำงานด้านภาษา
ได้อย่างชาญฉลาด

ตัวอย่างการใช้ NLP: การจัดประเภทข้อความอัตโนมัติ

ช่วยคัดกรองเนื้อหา ให้เราเห็นเฉพาะสิ่งที่เหมาะสมและเกี่ยวข้อง



ประโยชน์ที่ได้รับ



คัดกรองสแปมและ
ข้อความไม่เกี่ยวข้อง
ลดสิ่งรบกวน
ประหยัดเวลา



ปกป้องผู้ใช้จากเนื้อหา
ไม่เหมาะสม
โดยเฉพาะกลุ่มเยาวชน
และผู้ใช้ทั่วไป



ปรับปรุงประสบการณ์ผู้ใช้
ให้ดีขึ้น
ให้เนื้อหาที่มีคุณภาพ
และเกี่ยวข้องมากขึ้น



ถูกนำไปใช้อย่างแพร่หลาย
โดยบริษัทเทคโนโลยีชั้นนำ
เช่น Google, Meta, YouTube,
X (Twitter) และอื่น ๆ

ตัวอย่างการประยุกต์ใช้ NLP

Search Engine เข้าใจภาษามนุษย์



เข้าใจคำถามของผู้ใช้

วิเคราะห์ความหมาย เจตนา และบริบท



ค้นหาข้อมูลที่เกี่ยวข้อง

ดึงผลลัพธ์ที่ตรงประเด็นและ
ตอบใจมากที่สุด



แสดงผลลัพธ์ที่เข้าใจง่าย

สรุปคำตอบสำคัญในรูปแบบที่
ผู้ใช้เข้าใจได้ทันที



How many songs does blackpink have



🔍 ทั้งหมด

🖼️ ค้นรูป

📺 วิดีโอ

📄 ข่าวสาร

📍 Maps

⋮ เพิ่มเติม

👉 เครื่องมือ

ผลการค้นหาประมาณ 95,000,000 รายการ (0.54 วินาที)

Black Pink(BLACKPINK) **58 songs** in total * Mojim.com Lyrics.
Black Pink is a South Korean girl group formed by YG Entertainment.
The group consists of four members: Jisoo, Jennie, Rosé and Lisa.

<https://mojim.com> > ush176932-A2

Black Pink(BLACKPINK) 58 songs in total * Mojim.com Lyrics



NLP ช่วยให้เครื่องมือค้นหาเข้าใจภาษาของมนุษย์
และส่งมอบข้อมูลที่แม่นยำ รวดเร็ว และตรงความต้องการ

ตัวอย่างเทคโนโลยี NLP: เครื่องแปลภาษา (Machine Translation)

ช่วยแปลและตรวจสอบงานแปลให้ถูกต้อง รวดเร็ว และมีคุณภาพยิ่งขึ้น

1 ช่วยตรวจสอบงานแปล (Translation Quality Check)

ระบบตรวจพบข้อผิดพลาดและความไม่สอดคล้อง
เพื่อให้มนุษย์ตัดสินใจว่าจะยอมรับหรือแก้ไข

QA: พบ 2 ข้อผิดพลาด

ยอมรับทั้งหมด

เพิกเฉย

1 การสะกดคำผิด (Possible spelling mistake)

Segment 5

Remember that in reality, to learn English you must practice
atleast at least 10 minutes a day Monday to Sunday.

ยอมรับ

2 เครื่องหมายวรรคตอนไม่ตรงกัน (Source and target punctuation have different ending punctuation)

เพิกเฉย

Segment 4

If you aren't sure which course to enroll in, you can take our
English proficiency test.



การตัดสินใจโดยมนุษย์

นักแปลที่มีความรู้ทั้งสองภาษา
เป็นผู้ตัดสินใจสุดท้ายว่าจะ
เชื่อคำแนะนำของระบบ
หรือจะปรับแก้ไข



ประเภทข้อผิดพลาดที่ตรวจพบ

- การสะกดคำผิด
- เครื่องหมายวรรคตอนไม่ตรงกัน
- ไวยากรณ์ไม่ถูกต้อง
- การใช้คำไม่เหมาะสม
- ความไม่สอดคล้องของคำศัพท์

2 ช่วยแปลร่างเบื้องต้น (Draft Translation)

ระบบแปลร่างให้ก่อน แล้วนักแปลค่อยตรวจแก้ (Edit)
ช่วยลดเวลาและเพิ่มประสิทธิภาพการทำงาน

ภาษาต้นทาง (Source)

Los mejores cursos de inglés para
todos los niveles: principiantes,
básico, intermedio.



คำแปลร่างที่ระบบเสนอ (MT Draft)

The best English courses for all levels:
beginners, basic, intermediate.



นักแปลตรวจแก้ (Human Edit)

The best English courses for all levels: beginners, basic,
and intermediate.



ช่วยประหยัดเวลา

ปล่อยให้ระบบจัดการ
ประโยคง่าย ๆ
ส่วนนักแปลโฟกัสกับ
ประโยคที่ยากจริง ๆ



ผลลัพธ์ที่ดีขึ้น
งานแปลเร็วขึ้น
คุณภาพดีขึ้น
สม่ำเสมอมากขึ้น



ประโยชน์ที่ได้รับ



ลดข้อผิดพลาด

ตรวจจับข้อผิดพลาดที่
นักแปลอาจพลาดไป
ก่อนส่งมอบงาน



ประหยัดเวลา

ระบบแปลร่างและตรวจสอบ
ช่วยลดเวลาการทำงาน
ได้อย่างมาก



เพิ่มประสิทธิภาพนักแปล

โฟกัสกับงานที่ใช้ความคิด
และประโยคที่ซับซ้อน
ได้เต็มที่



คุณภาพงานสูงขึ้น

งานแปลถูกต้อง สม่ำเสมอ
และเป็นมืออาชีพมากขึ้น



รองรับหลายภาษา
และหลายงาน

ใช้ได้กับเอกสาร เว็บไซต์
แชท คำบรรยาย ฯลฯ



ตัวอย่างการใช้งาน NLP Chatbot ช่วยจองคิวตัดผม

Chatbot คือการทำให้เครื่องสามารถตอบโต้กับเราได้
ช่วยตอบคำถามและให้บริการลูกค้าจำนวนมากได้อย่างรวดเร็ว



1 ทักทายกับบอท

ลูกค้าพิมพ์เข้ามา บอทตอบกลับอัตโนมัติ



2 เลือกบริการและเวลา

บอทสอบถามบริการ วันที่ และเวลาที่ต้องการ






3 ยืนยันการจองและแจ้งราคา

บอทยืนยันการจอง พร้อมแจ้งรายละเอียดและราคา



4 เสร็จสิ้นการจอง

บอทยืนยันการจองเรียบร้อยแล้ว และส่งข้อมูลให้ลูกค้า



ประโยชน์ของ
Chatbot



ตอบลูกค้าได้ตลอด 24 ชั่วโมง
ไม่พลาดทุกการติดต่อ
ลดเวลาการรอลูกค้า




ลดภาระพนักงาน
ลดงานตอบแชท/รับโทรศัพท์
ไปโฟกัสบริการหน้าร้าน



ลดต้นทุน
ลดค่าใช้จ่ายในการจ้างพนักงาน
ดูแลแขกจำนวนมาก



เพิ่มความพึงพอใจลูกค้า
บริการรวดเร็ว สะดวก
ประสบการณ์ที่ดีขึ้น



NLP ทำงานตรงไหนในระบบ?

ภาพรวมการทำงานของ NLP Layer



1. รับข้อความจากผู้ใช้

รับข้อความจากช่องทางต่าง ๆ
เช่น เว็บไซต์, Facebook Messenger,
Slack และแพลตฟอร์มอื่น ๆ



2. NLP Layer ประมวลผล


NLP ทำความเข้าใจข้อความ วิเคราะห์
ความหมาย และดึงข้อมูลที่เกี่ยวข้อง
เพื่อตอบกลับผู้ใช้



3. ดึงข้อมูลและบันทึก

ดึงข้อมูลจาก Knowledge Base / CMS
เพื่อตอบกลับผู้ใช้ พร้อมบันทึกประวัติ
การโต้ตอบและผลการวิเคราะห์ลงใน
Data Store เพื่อใช้พัฒนาในอนาคต

ช่องทางการติดต่อ



ผู้ใช้ส่งข้อความ
ผ่านช่องทางต่าง ๆ



NLP

NATURAL LANGUAGE
PROCESSING (NLP) LAYER

- ✓ เข้าใจความหมาย
- ✓ วิเคราะห์เจตนา
- ✓ ดึงข้อมูลที่เกี่ยวข้อง

ประมวลผลและทำความเข้าใจ
ข้อความของผู้ใช้



KNOWLEDGE BASE / CMS
(Source Content)

แหล่งข้อมูลต้นทางที่เตรียมไว้
เช่น FAQ, บทความ, เอกสาร



DATA STORE
(Interaction History & Analytics)

เก็บประวัติการโต้ตอบและผลการ
วิเคราะห์ เพื่อใช้ต่อยอดและพัฒนา
NLP ให้ฉลาดยิ่งขึ้น



ประโยชน์ที่ได้รับ



ตอบกลับผู้ใช้ได้รวดเร็ว
แม่นยำ และตรงประเด็น



บันทึกและวิเคราะห์ข้อมูล
เพื่อเข้าใจผู้ใช้งานมากขึ้น



นำข้อมูลไปพัฒนา NLP
ให้ฉลาดและเก่งขึ้นในอนาคต



NLP ประยุกต์ใช้กับอะไรได้บ้าง?

หลากหลายแอปพลิเคชันที่ช่วยให้ชีวิตและการทำงานง่ายขึ้น

แอปพลิเคชันจริงของ NLP ยังมีอีกมาก ขึ้นอยู่กับว่าเราจะจินตนาการไปได้ไกลแค่ไหน



Transcriber

ถอดเทปเสียง
เป็นข้อความอัตโนมัติ
ไม่ต้องถอดเอง



**Writing
Improvement
Assistant**

ช่วยตรวจแก้คำผิด
ไวยากรณ์ และปรับปรุง
การเขียนให้ดีขึ้น



**Automated
Tutor**

ตอบโต้ ถาม-ตอบ
และช่วยให้เราเรียนรู้
ได้ดียิ่งขึ้น



**Virtual
Psychologist/
Therapist**

พูดคุย รับฟัง และให้คำแนะนำ
เบื้องต้นเหมือนนักบำบัด
ช่วยดูแลจิตใจเบื้องต้น



**Line Urgency
Detection**

จัดลำดับความสำคัญของข้อความ
จากหลายแชต ช่วยแจ้งเตือนว่า
ข้อความไหนควรรับตอบก่อน



**Book
Summarization**

สรุปเนื้อหาหนังสือ
ให้สั้นกระชับ เข้าใจง่าย
ประหยัดเวลาในการอ่าน



**Report
Generator**

สรุปรายงานการประชุม
หรือรายงานวิจัยต่าง ๆ
ให้อัตโนมัติ



**ไอเดียคือ
ขีดจำกัด**

ทั้งหมดนี้คือเพียงตัวอย่าง ยังมีอีกมากมายที่สามารถนำ NLP ไปประยุกต์ใช้
ขึ้นอยู่กับไอเดียและความต้องการของเรา!



คำถามชวนคิด

ถ้าคอมพิวเตอร์เข้าใจภาษาได้
เรา仍将สามารถนำมาแทนคน
ในส่วนไหนได้อีกบ้าง?



ลองแชร์ไอเดียของคุณในคอมเมนต์
เพื่อแลกเปลี่ยนมุมมองและเรียนรู้ไปด้วยกัน



NLP คือเทคโนโลยีที่กำลังมาแรง
องค์กรชั้นนำทั่วโลกต่างเร่งพัฒนา เพื่อนำไปสร้าง
นวัตกรรมและเพิ่มประสิทธิภาพในระบบต่าง ๆ



สร้างคุณค่า เพิ่มประสิทธิภาพ
และขับเคลื่อนนวัตกรรมให้กับองค์กร



The Role of Linguistics in NLP

ภาษาศาสตร์ คือกรอบทฤษฎีที่ช่วยให้เราเข้าใจภาษาอย่างเป็นระบบ



ภาษาศาสตร์ (Linguistics) ทำหน้าที่เป็น “กรอบทฤษฎี” (Theoretical Framework) ที่ช่วยให้เราเข้าใจโครงสร้างและกฎเกณฑ์ของภาษา นำไปสู่การวิเคราะห์ข้อมูลภาษาได้อย่างแม่นยำ

ภาษาศาสตร์ช่วยให้เราเข้าใจว่า...

Aa

คำคืออะไร

คำ (Word) มีความหมาย และหน้าที่อย่างไร ในบริบทของภาษา



ประโยค/บทสนทนา ประกอบด้วยส่วนใดบ้าง

โครงสร้างประโยค และความสัมพันธ์ ระหว่างคำ



กฎเกณฑ์ทางภาษา

ไวยากรณ์ (Grammar) และกฎการใช้ภาษาที่ทำให้เกิดความหมาย



ผลต่อการวิเคราะห์

ความเข้าใจภาษาเชิงลึก ช่วยให้ผลการวิเคราะห์ แม่นยำและน่าเชื่อถือ



เป้าหมาย

เข้าใจภาษาอย่างเป็นระบบ เพื่อพัฒนาโมเดลและกระบวนการ NLP ที่ให้ผลลัพธ์ที่ดีขึ้นอย่างต่อเนื่อง

เทคโนโลยีเบื้องหลัง NLP: 2 ส่วนหลัก

1 Automatic Text Processing (การประมวลผลข้อความอัตโนมัติ)

เขียนโปรแกรมเพื่อดึงข้อมูลจากแหล่งต่าง ๆ
และเตรียมข้อมูลให้อยู่ในรูปแบบที่พร้อมวิเคราะห์



ดึงข้อมูลจาก
หลากหลายแพลตฟอร์ม



ตัดคำ, ทำความสะอาด
และทำให้ข้อมูลเป็นมาตรฐาน



ได้ข้อมูลที่มีคุณภาพ
พร้อมสำหรับการวิเคราะห์

2 Machine Learning (อัลกอริทึมที่ทำให้ NLP ฉลาด)

อัลกอริทึมที่เรียนรู้จากข้อมูล เพื่อค้นหา Pattern,
ความสัมพันธ์ และสร้างผลลัพธ์ที่ชาญฉลาด



จะกล่าวถึงในหัวข้อถัดไป

ส่วนที่ 1: Automatic Text Processing ประกอบด้วย

1.1 ดึงข้อมูลจากแพลตฟอร์มต่าง ๆ (Collect Data)



Facebook



Twitter



Instagram



YouTube



Pantip



อื่น ๆ

1.2 ประมวลผลข้อความ (Text Processing)



ตัดคำ (Word Segmentation)

แบ่งข้อความออกเป็นคำ
ที่มีความหมาย



ทำความสะอาด (Text Cleaning)

ลบคำที่ไม่ต้องการ, URL,
ตัวเลข, สัญลักษณ์, emoji,
RT, @username เป็นต้น

Aa

ทำให้เป็นมาตรฐาน
(Normalization)

ทำให้ข้อความอยู่ในรูปแบบ
เดียวกัน เช่น แปลงตัวพิมพ์,
ตัดช่องว่างเกิน, แก้คำย่อ

1.3 ผลลัพธ์: ข้อมูลที่มีคุณภาพ พร้อมนำไปวิเคราะห์



ข้อมูลสะอาด, เป็นมาตรฐาน, ลดความซ้ำซ้อน และพร้อมสำหรับการทำ NLP ขั้นสูง



ประเด็นสำคัญ


Automatic Text Processing คือขั้นตอนสำคัญในการเตรียมวัตถุดิบ (ข้อความดิบ) ให้พร้อมใช้งาน
หากข้อมูลไม่สะอาด ผลลัพธ์จากขั้นตอนต่อ ๆ ไปก็จะไม่แม่นยำ



API Call: การดึงข้อมูล (Data Collection)

ขั้นตอนแรกของการทำ Automatic Text Processing

ดึงข้อมูลจากแหล่งต่าง ๆ เช่น Social Media หรือเว็บไซต์ ผ่าน API (Application Programming Interface)



สรุป

- แอปของเรา (Client) ส่ง Request ผ่านอินเทอร์เน็ตไปยัง API
- API ไปดึงข้อมูลจาก Web Server และ Database
- ส่งข้อมูลกลับมาเป็น Response ให้เรา



เทคโนโลยี API คือสิ่งที่เราใช้อยู่ทุกวัน
เมื่อเปิดเว็บเบราว์เซอร์หรือแอปต่าง ๆ

Data is Dirty.

Language Data is Even Dirtier.

ตัวอย่างข้อมูลจากโซเชียลมีเดียที่มีปัญหาหลากหลาย ทำให้ไม่สามารถนำไปวิเคราะห์ได้ทันที

ตัวอย่างข้อมูลดิบจากทวิต (Twitter)

-  RT @MatichonOnline: “บ๊ิกตุ” ลั่นรบ.ทำอะไรยี้ตคน.ไม่ใช่ติดคุกแล้วหนิ เล่นมุขพรรคร่วม “พลังประช.ภูมิใจไทย” <https://t.co/9nmOBjnhqr> via @มติชนอ...
-  บกพร่องโดยสุจริต VS อยู่-ไม่-เป็น | ชัยคดีโกง | 10 พ.ย. 62 | (3/3) <https://t.co/atUF6PrXdx> via @YouTube
-  ขอให้เลิกถึงการท่องเที่ยวภายนอกหน้าด้วย คะ

ปัญหาที่พบบ่อยในข้อมูลภาษา

-  **คำนำหน้าและชื่อผู้ใช้น้อย**
เช่น RT, @username, via... ไม่ใช่เนื้อหาที่ต้องการวิเคราะห์
-  **มีลิงก์ (URL) ปะปน**
ไม่เกี่ยวข้องกับเนื้อหา แต่รบกวนการประมวลผล
-  **ข้อความไม่ครบถ้วน**
ข้อมูลขาดหายเพราะข้อจำกัดของ API
-  **ตัวเลขและสัญลักษณ์ปนอยู่**
เช่น วันที่, ตัวเลข, เครื่องหมายต่าง ๆ
-  **คำสะกดผิด / ใช้คำผิด**
เช่น “ค้า” ควรเป็น “ขาย” ทำให้ความหมายเพี้ยน



**ทำไมต้องทำ
ความสะอาดข้อมูล?**

หากข้อมูลมีจำนวนมาก (หมื่น-แสนแถว) การลบหรือแก้ไขด้วยมือจะใช้เวลามากและไม่สามารถทำได้จริง
การเขียนโปรแกรมทำความสะอาดข้อมูล ช่วยให้ทำได้อัตโนมัติ รวดเร็ว และแม่นยำ

Stop Words

ขั้นตอนสำคัญในการทำความสะดวกข้อมูล (Text Cleaning)



Stop Words คือ คำที่ไม่ได้ช่วยเพิ่มความหมายให้กับประโยคมากนัก
การตัดออกช่วยลดความซ้ำซ้อนและทำให้การวิเคราะห์มีประสิทธิภาพมากขึ้น



ตัวอย่างภาษาอังกฤษ

- คำบุพบท: on, over, for
- คำนำหน้านาม: a, the
- กริยาช่วย: is, am, are, was, were, be
- อื่น ๆ: and, or, but, to, of, in, out



เช่น: is, on, over, the, for, a, out



ตัวอย่างภาษาไทย

เช่น: กว่า, กัน, กับ, ขอ, คือ, จะ,
สุด, ว่า, ได้, ใน



คำเหล่านี้มักพบบ่อย
แต่มีผลต่อความหมายน้อย



ไม่มีลิสต์มาตรฐานตายตัว

- ขึ้นอยู่กับ Use Case และวัตถุประสงค์ของงาน
- คำที่ดูเหมือนไม่สำคัญ อาจมีความหมายสำคัญต่อการวิเคราะห์ได้
- พิจารณาจากคำที่พบบ่อยที่สุดในคลังข้อมูล เช่น Top 50 หรือ Top 100 คำ
- เลือกตัดคำที่ไม่ส่งผลต่อความหมายหลักออก เพื่อเพิ่มประสิทธิภาพของโมเดล



ประโยชน์ที่ได้รับ



ลดความซ้ำซ้อน
ของข้อมูล



ทำให้โมเดลเรียนรู้
ประเด็นสำคัญได้ดีขึ้น



เพิ่มประสิทธิภาพ
ในการวิเคราะห์



เช็คลิสต์สำหรับการทำความสะอาดข้อมูลข้อความ

คำถามสำคัญที่ต้องถามตัวเอง

1



เราจะจัดการกับสัญลักษณ์ ตัวเลข และส่วนที่ไม่ใช่ภาษาอย่างไร?

กำหนดแนวทางการเก็บไว้ แทนที่ หรือลบออก ให้เหมาะสมกับงานวิเคราะห์

2



เราต้องการตัด Stop Words ออกหรือไม่?

พิจารณาจาก Use Case และคำที่พบบ่อยในคลังข้อมูล (เช่น Top 50 หรือ Top 100 คำ)

3

Aa

เราต้องการแปลงข้อความเป็นตัวพิมพ์เล็กทั้งหมดหรือไม่? (Lowercase)

- ช่วยให้คำที่ควรเหมือนกันถูกมองเป็นคำเดียวกัน เช่น Animals = animals
- ตัวอย่าง: Dan Brown → dan brown (ระวังอาจกระทบชื่อเฉพาะ)

4



เราต้องการทำ Stemming หรือไม่?

- ตัดคำให้เหลือรากศัพท์ เพื่อรวมคำที่มีความหมายเดียวกัน
- ตัวอย่าง: searched, searching → search



สิ่งที่ควรทราบ



ทั้งหมดขึ้นอยู่กับ Application

ไม่มีคำตอบที่ตายตัว ต้องเลือกให้เหมาะสมกับวัตถุประสงค์ของงาน



ข้อสังเกตสำหรับภาษาไทย

มักไม่ทำ Lowercase หรือ Stemming เพราะภาษาไทยไม่มีตัวพิมพ์เล็ก-ใหญ่ และไม่มีการผันคำแบบภาษาอังกฤษ



เป้าหมาย

ทำให้ข้อมูลสะอาด เป็นมาตรฐาน และพร้อมสำหรับการวิเคราะห์ เพื่อให้โมเดลเรียนรู้ได้แม่นยำและมีประสิทธิภาพ

```
import pythainlp, attacut  
test_sentence = "ระฆังดีไม่ตีก็ดัง"
```

```
tokens = pythainlp.word_tokenize(test_sentence, engine="attacut")
```

```
▶ pythainlp.word_tokenize('ระฆังดีไม่ตีก็ดัง แต่คนดีไม่ต้องตีมันก็ดัง', engine='attacut')
```

```
☞ ['ระฆัง',  
   'ดี',  
   'ไม่',  
   'ตี',  
   'ก็',  
   'ดัง',  
   '.',  
   'แต่',  
   'คน',  
   'ดี',  
   'ไม่',  
   'ต้อง',  
   'ตี',  
   'มัน',  
   'ก็',  
   'ดัง']
```

```
[5] pythainlp.word_tokenize('พระมหาไพรวัลย์ถึงกับต้องบอกให้เจเจี่ยมแบบอรุ่มเจ้าะอีกรอบ', engine='attacut')
```

```
['พระมหาไพรวัลย์',  
 'ถึง',  
 'กับ',  
 'ต้อง',  
 'บอก',  
 'ให้',  
 'เจเจี่ยม',  
 'แบบ',  
 'อรุ่มเจ้าะ',  
 'อี',  
 'กรอบ']
```

```
import nltk
nltk.download('punkt')
```

```
doc = nltk.word_tokenize("Apple is looking at buying U.K. startup for $1 billion")
doc
```

```
['Apple',
 'is',
 'looking',
 'at',
 'buying',
 'U.K.',
 'startup',
 'for',
 '$',
 '1',
 'billion']
```



การตัดคำไม่ใช่ปัญหาใหญ่ที่สุดอีกต่อไป

เมื่อเทียบกับความท้าทายอื่น ๆ ใน NLP



ภาษาไทยตัดคำยาก

ไม่มีช่องว่างแบ่งคำ ทำให้การตัดคำเป็นหนึ่งในความท้าทายแรก ๆ ของ NLP



NLP แก้ปัญหาการตัดคำได้ดีขึ้นมาก

เทคโนโลยีปัจจุบันสามารถตัดคำได้แม่นยำในระดับที่น่าพอใจแล้ว



ความท้าทายที่แท้จริงอยู่ที่ “ความเข้าใจ”

การทำให้เครื่องเข้าใจความหมายของภาษา คือโจทย์ที่ยากกว่า และเกี่ยวข้องกับเทคโนโลยี Machine Learning



ก้าวต่อไปของ NLP

จากการ “ตัดคำ” สู่การ “เข้าใจความหมาย” เพื่อการใช้งานที่ชาญฉลาดยิ่งขึ้น

ความแม่นยำของการตัดคำ (Word Segmentation)



96%

ข้อความมาตรฐาน
(Standard Text)



80%

ข้อความโซเชียลมีเดีย
(Social Media Text)



สรุปประเด็นสำคัญ

การตัดคำไม่ใช่ปัญหาใหญ่ที่สุดอีกต่อไป
เมื่อเทียบกับความท้าทายอื่น ๆ ใน NLP

หัวใจสำคัญคือ “การเข้าใจความหมาย”
ซึ่งเกี่ยวข้องกับเทคโนโลยี Machine Learning

เทคโนโลยีเบื้องหลัง NLP: 2 ส่วนหลัก

1 Automatic Text Processing (การประมวลผลข้อความอัตโนมัติ)

เขียนโปรแกรมเพื่อดึงข้อมูลจากแหล่งต่าง ๆ
และเตรียมข้อมูลให้อยู่ในรูปแบบที่พร้อมวิเคราะห์



ดึงข้อมูลจาก
หลากหลายแพลตฟอร์ม



ตัดคำ, ทำความสะอาด
และทำให้ข้อมูลเป็นมาตรฐาน



ได้ข้อมูลที่มีคุณภาพ
พร้อมสำหรับการวิเคราะห์

2 Machine Learning (อัลกอริทึมที่ทำให้ NLP ฉลาด)

อัลกอริทึมที่เรียนรู้จากข้อมูล เพื่อค้นหา Pattern,
ความสัมพันธ์ และสร้างผลลัพธ์ที่ชาญฉลาด



ทำให้ NLP สามารถเข้าใจภาษา คาดเดา
จัดกลุ่ม สรุปความ และอีกมากมาย
ได้เหมือนมนุษย์

ส่วนที่ 2: Machine Learning คืออะไร?



หัวใจของ NLP

Machine Learning คืออัลกอริทึมที่ทำให้เครื่องสามารถ “เรียนรู้”
จากข้อมูลจำนวนมาก แล้วทำหน้าที่ทางภาษาแทนคนได้
อย่างชาญฉลาดและแม่นยำ



มีซอฟต์แวร์สำเร็จรูปให้ใช้

เช่น Speech-to-Text, แปลภาษาอัตโนมัติ, สรุปข้อความ, แชทบอท
เราสามารถซื้อใช้บริการได้เลย



Speech-to-Text
แปลงเสียงพูด
เป็นตัวอักษร



Machine Translation
แปลภาษาข้ามภาษา
อัตโนมัติ



Text Summarization
สรุปใจความสำคัญ
ของข้อความ



Chatbot
แชทบอทตอบคำถาม
อัตโนมัติ

...



ใน EP นี้ เราจะมาดูการสร้างโมเดลของเราเองตั้งแต่ต้น

เพื่อให้เหมาะกับ Application เฉพาะของเรา
เราจะเรียนรู้ขั้นตอนและวิธีการสร้างโมเดล NLP ด้วยตัวเอง



ประเด็นสำคัญ

Machine Learning คือส่วนที่ทำให้ NLP ฉลาดและทรงพลัง

แม้จะมีซอฟต์แวร์สำเร็จรูปให้ใช้ แต่การสร้างโมเดลเองจะช่วยให้เราปรับแต่งได้ตรงกับความต้องการของเราอย่างแท้จริง




Machine Learning Techniques in NLP

เทคนิค Machine Learning ที่ใช้ใน NLP

เทคนิคหลักที่ใช้ใน NLP มี 3 กลุ่มใหญ่ ๆ โดยในสไลด์นี้เราจะเริ่มจากกลุ่มแรก: **Supervised Learning**

1 Supervised Learning



เรียนรู้จากข้อมูลที่มีคำตอบ (ป้ายกำกับ) เพื่อทำนายผลลัพธ์หรือจัดประเภทข้อมูล

เราจะเริ่มจากกลุ่มนี้ก่อน

2 Unsupervised Learning



เรียนรู้จากข้อมูลที่ไม่มีคำตอบ เพื่อค้นหารูปแบบความสัมพันธ์ หรือจัดกลุ่มข้อมูลด้วยตัวเอง

3 Transfer Learning



นำความรู้ที่ได้จากงานหนึ่งไปประยุกต์ใช้กับอีกงานหนึ่ง ช่วยให้โมเดลเรียนรู้ได้ดีขึ้นแม้มีข้อมูลน้อย

Supervised ML: Learn from Examples

เรียนรู้จากตัวอย่าง เพื่อกำหนดผลลัพธ์



หลักการของ Supervised Learning คือการใช้ข้อมูลที่มีคำตอบแล้ว (Input-Output Pairs) ให้ Machine Learning Algorithm เรียนรู้ความสัมพันธ์ระหว่าง Input และ Output ด้วยตัวเอง เรียกว่า **Training Model** หรือการฝึกฝนโมเดล

1. Training Data

เตรียมข้อมูลตัวอย่างจำนวนมาก ประกอบด้วยคู่ของ Input และ Output

Input	Output
ตัวอย่าง 1	คำตอบ 1
ตัวอย่าง 2	คำตอบ 2
ตัวอย่าง 3	คำตอบ 3
...	...
ตัวอย่าง N	คำตอบ N



2. Machine Learning Algorithm

อัลกอริทึมเรียนรู้ความสัมพันธ์ระหว่าง Input และ Output จากข้อมูลตัวอย่าง



3. Model Training

อัลกอริทึมปรับปรุงพารามิเตอร์ภายใน จนสามารถทำนาย Output ได้ใกล้เคียงที่สุด



สรุป

- ต้องมีข้อมูลที่มีคำตอบ (Input-Output Pairs)
- ใช้ข้อมูลจำนวนมาก (หลักพัน-หลักหมื่นตัวอย่าง) เพื่อให้โมเดลเรียนรู้ได้แม่นยำ
- เป้าหมายคือให้โมเดลสามารถทำนาย Output จาก Input ใหม่ที่ไม่เคยเห็นมาก่อน

Supervised ML: Learn from Examples

เรียนรู้จากตัวอย่าง เพื่อให้เครื่องเรียนรู้ความสัมพันธ์ระหว่าง Input และ Output


1 ตัวอย่าง: การตัดคำภาษาไทย

“ Input คือประโยคดิบ
Output คือการตัดคำที่ถูกต้อง
ป้อนตัวอย่างจำนวนมากเพื่อให้
เครื่องเรียนรู้รูปแบบการตัดคำเอง
ไม่ต้องเขียนกฎไวยากรณ์

Training Data (ตัวอย่าง)

Input (ประโยคดิบ)	Output (การตัดคำ)
สวัสดีครับ	สวัสดี ครับ
ถามหน่อยครับ	ถาม โน้ย ครับ
...	...
ขอโทษค่ะ อะไรนะคะ	ขอโทษ ค่ะ อะไร นะ คะ

Machine Learning Algorithm



หลักการ

เมื่อมีตัวอย่างการตัดคำที่ถูกต้อง
จำนวนมาก เครื่องจะเรียนรู้รูปแบบ
การแบ่งคำด้วยตัวเอง
จากตัวอย่างล้วน ๆ

2 ตัวอย่าง: Sentiment Analysis

“ Input คือข้อความรีวิว
Output คือ Label ความรู้สึก
(เชิงบวก / เชิงลบ)
ต้องมีตัวอย่างจำนวนมากและ
มีคนช่วย Label ให้ถูกต้อง
เพื่อให้เครื่องเข้าใจบริบทที่ซับซ้อน

Training Data (ตัวอย่าง)

Input (ข้อความรีวิว)	Output (Label)
อาหารเหมาะสำหรับสัตว์เลี้ยงเท่านั้น	😞
ไกลแค่ไหนก็ต้องมาทาน	😊
...	...
พนักงานบริการเต็มใจมาก	😞

Machine Learning Algorithm



ทำไมต้องมีตัวอย่างมาก

- ✓ บริบทของภาษาซับซ้อน
คำพูดเดียวกันอาจมีความหมาย
แตกต่างกันได้
- ✓ ช่วยให้เครื่องแยกแยะความรู้สึก
ได้แม่นยำมากขึ้น
- ✓ ลดความผิดพลาดในการทำนาย
ในสถานการณ์ใหม่ ๆ



สรุป

ไม่ว่าเป็นการตัดคำ หรือการวิเคราะห์ความรู้สึก หลักการคือ “เรียนรู้จากตัวอย่าง” ยิงมี Training Data ที่หลากหลายและถูกต้องมากเท่าไร
โมเดลก็จะยิ่งเรียนรู้ได้ดีและทำงานได้แม่นยำมากขึ้น




Machine Learning Techniques in NLP

เทคนิค Machine Learning ที่ใช้ใน NLP

เทคนิคหลักที่ใช้ใน NLP มี 3 กลุ่มใหญ่ ๆ โดยในสไลด์นี้เราจะเริ่มจากกลุ่มแรก: **Supervised Learning**

1 Supervised Learning



เรียนรู้จากข้อมูลที่มี
คำตอบ (ป้ายกำกับ)
เพื่อทำนายผลลัพธ์
หรือจัดประเภทข้อมูล

2 Unsupervised Learning



เรียนรู้จากข้อมูลที่ไม่มี
คำตอบ เพื่อค้นหารูปแบบ
ความสัมพันธ์ หรือจัดกลุ่ม
ข้อมูลด้วยตัวเอง

3 Transfer Learning



นำความรู้ที่ได้จากงานหนึ่ง
ไปประยุกต์ใช้กับอีกงานหนึ่ง
ช่วยให้โมเดลเรียนรู้ได้ดีขึ้น
แม้มีข้อมูลน้อย

Unsupervised Learning คืออะไร?

ให้เครื่องเรียนรู้จาก Input เพียงอย่างเดียว เพื่อค้นหา Pattern ที่ซ่อนอยู่ในข้อมูล

แนวคิดหลัก



มีเพียง Input เท่านั้น

ไม่มีผลลัพธ์ (Output) หรือป้ายกำกับ (Label)



เรียนรู้หา Pattern ด้วยตัวเอง


ค้นหาโครงสร้าง ความสัมพันธ์ หรือรูปแบบ
ที่ซ่อนอยู่ในข้อมูล



ตัวอย่างการใช้งาน

การจัดกลุ่มข้อมูลตามธรรมชาติ (Natural Grouping),
การลดมิติข้อมูล (Dimensionality Reduction),
การหาความสัมพันธ์ที่ผิดปกติ (Anomaly Detection)


Input เท่านั้น



Unsupervised
ML Algorithm



ค้นพบ Pattern / โครงสร้าง



สรุป

- ✓ Unsupervised Learning ไม่ต้องใช้ Output หรือ Label
- ✓ เครื่องจะเรียนรู้โครงสร้างและ Pattern ที่ซ่อนอยู่ในข้อมูลด้วยตัวเอง
- ✓ ช่วยให้เราเข้าใจข้อมูลจำนวนมาก และใช้ประโยชน์จากข้อมูลได้อย่างมีประสิทธิภาพ

“

ให้เครื่องเรียนรู้ด้วยตัวเอง
เพื่อค้นพบสิ่งที่เรายังไม่รู้
จากข้อมูลที่มีอยู่

”

Topic Modeling: จัดกลุ่มหัวข้ออัตโนมัติ

ให้เครื่องค้นหาและจัดกลุ่มหัวข้อจากเอกสารจำนวนมาก โดยไม่ต้องกำหนดล่วงหน้า



มีเอกสารจำนวนมาก

เช่น บทความ, รีวิว, ทวิต
ที่ยังไม่ทราบหมวดหมู่



ให้เครื่องเรียนรู้และค้นหารูปแบบ

Machine Learning Algorithm
จะวิเคราะห์คำและบริบทในเอกสาร
เพื่อหาความสัมพันธ์



จัดกลุ่มหัวข้ออัตโนมัติ

เครื่องจะจัดเอกสารออกเป็นกลุ่มต่าง ๆ
โดยอัตโนมัติ ตามหัวข้อที่มีความสัมพันธ์กัน




ประโยชน์


- เข้าใจภาพรวมของข้อมูลจำนวนมากได้รวดเร็ว
- จัดระเบียบและค้นหาข้อมูลได้ง่ายขึ้น
- ช่วยในการตัดสินใจและวิเคราะห์เชิงลึก



เอกสาร / ทวิต
จำนวนมาก



Machine Learning
Algorithm



กลุ่มที่ 1: ภาพยนตร์



เอกสารที่เกี่ยวข้อง
กับภาพยนตร์

กลุ่มที่ 2: ตลาดหุ้น / การเงิน



เอกสารที่เกี่ยวข้อง
กับตลาดหุ้นหรือ
การเงิน

กลุ่มที่ 3: กีฬา



เอกสารที่เกี่ยวข้อง
กับกีฬา




สรุป

Topic Modeling ช่วยให้เราแบ่งกลุ่มเอกสารจำนวนมากออกเป็นหัวข้อที่เกี่ยวข้องกันได้โดยอัตโนมัติ
โดยไม่ต้องกำหนดจำนวนกลุ่มล่วงหน้า และไม่ต้องบอกว่าแต่ละกลุ่มคืออะไร

Word Clustering: หลายความหมายซ่อนอยู่

Unsupervised Learning ช่วยให้เห็นว่า “คำหนึ่งคำ” อาจมีหลายความหมาย

ตัวอย่าง: การจัดกลุ่มคำว่า “chair”



ประโยชน์ของ Word Clustering



ค้นพบความหมายที่ซ่อนอยู่

ช่วยให้เห็นว่าคำเดียวกันอาจมีหลายความหมายตามบริบทการใช้งาน



เข้าใจ Concept ได้ลึกซึ้ง

ช่วยให้เข้าใจความสัมพันธ์เชิงความหมายของคำในระดับแนวคิด



ประยุกต์ใช้ได้หลากหลาย

ช่วยปรับปรุงผลลัพธ์ในงานต่าง ๆ เช่น การค้นหา, การแปล, การจัดหมวดหมู่เนื้อหา



ตัวอย่างภาษาไทย
“แชร์”



ความหมายที่ 1: เฟอร์นิเจอร์

เช่น โต๊ะแชร์, เก้าอี้แชร์ (เฟอร์นิเจอร์ไม้)



ความหมายที่ 2: ประธาน / ผู้บริหาร

เช่น แชร์บริษัท, แชร์โครงการ (ประธานหรือผู้รับผิดชอบหลัก)

Word Clustering ช่วยให้เราจับกลุ่มความหมายและเข้าใจข้อมูลภาษาได้แม่นยำและลึกซึ้งยิ่งขึ้น




Machine Learning Techniques in NLP

เทคนิค Machine Learning ที่ใช้ใน NLP

เทคนิคหลักที่ใช้ใน NLP มี 3 กลุ่มใหญ่ ๆ โดยในสไลด์นี้เราจะเริ่มจากกลุ่มแรก: **Supervised Learning**

1 Supervised Learning



เรียนรู้จากข้อมูลที่มีคำตอบ (ป้ายกำกับ) เพื่อทำนายผลลัพธ์หรือจัดประเภทข้อมูล

2 Unsupervised Learning



เรียนรู้จากข้อมูลที่ไม่มีคำตอบ เพื่อค้นหารูปแบบความสัมพันธ์ หรือจัดกลุ่มข้อมูลด้วยตัวเอง

3 Transfer Learning



นำความรู้ที่ได้จากงานหนึ่งไปประยุกต์ใช้กับอีกงานหนึ่ง ช่วยให้โมเดลเรียนรู้ได้ดีขึ้นแม้มีข้อมูลน้อย



เทคนิคใหม่ที่มาแรง

Transfer Learning เป็นเทคนิคใหม่ล่าสุดที่กำลังได้รับความนิยมอย่างมากในวงการ NLP เนื่องจากช่วยเพิ่มประสิทธิภาพและลดเวลาการฝึกโมเดลได้อย่างมาก





Transfer Learning

เทคนิคที่ใหม่ที่สุด และปฏิวัติวงการ NLP

จุดเด่นของ Transfer Learning คือ เราจะไม่ให้เครื่องเริ่มเรียนรู้จากศูนย์ แต่จะแบ่งออกเป็น 2 ขั้นตอน ทำให้โมเดลมีพื้นฐานความเข้าใจภาษามาก่อน ส่งผลให้ทำงานได้แม่นยำขึ้นมาก


1

Pretraining

ให้เครื่องอ่านข้อมูลภาษาจำนวนมหาศาล จากอินเทอร์เน็ต (อย่างน้อย 50GB+)



ข้อมูลจากอินเทอร์เน็ต
50GB+
เทียบเท่าหนังสือ
เป็นแสนเล่ม



เรียนรู้คำศัพท์ โครงสร้างประโยค และไวยากรณ์ของภาษา เหมือนกับเครื่องได้เรียนภาษามาก่อนที่จะไปทำงานเฉพาะทาง

2

Fine-tuning

นำโมเดลที่เก่งภาษาแล้ว มาเทรนต่อด้วย Training Data เฉพาะงานที่เราต้องการ

Training data (ตัวอย่างงาน Sentiment Analysis)

Input (ข้อความ)	Output (Label)
อาหารเหมาะสำหรับสัตว์เลี้ยงเท่านั้น	😞
ไกลแค่ไหนก็ต้องมาทาน	😊
...	...
พนักงานบริการเต็มใจมาก	😞

เครื่องจะเรียนรู้งานเฉพาะทางจากข้อมูลที่เรา มี เช่น งาน Sentiment Analysis, Text Classification, ฯลฯ ทำให้ผลลัพธ์แม่นยำและมีประสิทธิภาพสูง



ผลลัพธ์ที่เปลี่ยน
วงการ NLP



ได้รับความนิยมอย่างมาก
ในช่วงปี 2017 - 2018



ทำให้วงการ NLP
ก้าวกระโดดไปอีกขั้น



Bag of Words (BoW)

เทคนิคพื้นฐาน: เปลี่ยนข้อความให้เป็นตัวเลข

ก่อนจะสร้างเป็นโมเดลภาษา สิ่งที่ต้องทำเป็นพื้นฐานก่อนคือ **Bag of Words**



เทคนิคที่ใช้เปลี่ยน “ข้อความ” ให้เป็น “ตัวเลข” เพื่อให้คอมพิวเตอร์เข้าใจ



มันจะนับว่ามีคำได้บ้างในข้อความ โดยไม่สนใจลำดับของคำ



เทคนิคนี้ช่วยให้รู้ว่าคำไหนสำคัญ

1. ข้อความ (Text)

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



2. ถุงคำ (Bag of Words)



3. เวกเตอร์คำ (Word Vector / Count Vector)

คำ (Word)	จำนวน (Count)
it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
fairy	1
...	...

ได้เวกเตอร์ตัวเลขที่แทนข้อความนี้ เครื่องคอมพิวเตอร์สามารถนำไปประมวลผลต่อไป

ประโยชน์ของ
Bag of Words



ทำให้ข้อมูลข้อความอยู่ในรูปแบบที่คอมพิวเตอร์เข้าใจได้



ช่วยวิเคราะห์ความถี่ของคำ และหาคำที่สำคัญในเอกสาร



เป็นพื้นฐานของเทคนิค NLP ที่ซับซ้อนขึ้นในขั้นต่อไป

fx

TF-IDF

(Term Frequency-Inverse Document Frequency)

คือ อัลกอริทึมหรือสถิติที่ใช้ในการประเมินว่า “คำคำหนึ่งมีความสำคัญมากน้อยแค่ไหนในเอกสารชุดนั้น” เป็นเครื่องมือยอดนิยมในงานด้านการประมวลผลภาษาธรรมชาติ (NLP) และระบบค้นหาข้อมูล (Information Retrieval)

$$\begin{aligned} \text{TF-IDF}_{t,d} &= \text{TF}_{t,d} \cdot \text{IDF} \\ &= \text{TF}_{t,d} \cdot \log\left(\frac{N+1}{\text{DF}_t + 1}\right) \end{aligned}$$

TF_{t,d} : ความถี่ของคำ *t* ในเอกสาร *d* (Term Frequency)
DF_t : จำนวนเอกสารที่มีคำ *t* ปรากฏอยู่ (Document Frequency)
N : จำนวนเอกสารทั้งหมดในชุดข้อมูล (Total Number of Documents)

1. TF-IDF ทำงานอย่างไร? (สูตรและการแปลความ)

ส่วนที่ 1: TF (Term Frequency) ความถี่ของคำ



“คำนี้ปรากฏบ่อยแค่ไหนในเอกสารชิ้นนี้?”

- วิธีคิด: จำนวนครั้งที่คำนั้นปรากฏในเอกสาร / จำนวนคำทั้งหมดในเอกสารนั้น
- การแปลความ: ยิ่งคำปรากฏบ่อย คำ TF ก็ยิ่งสูง (แสดงว่าคำนั้นจะสำคัญกับบทความนี้)

ส่วนที่ 2: IDF (Inverse Document Frequency) ความหายาก (ความหายาก) ของคำ



“คำนี้เป็นคำโหลที่โหลไปทั่วทุกเอกสารหรือเปล่า?”

- วิธีคิด: $\log\left(\frac{\text{จำนวนเอกสารทั้งหมด}}{\text{จำนวนเอกสารที่มีคำนี้ปรากฏ}}$
- การแปลความ:
 - ถ้าคำนั้นโหลไปทั่วในเอกสารแทบทุกฉบับ (เช่น “และ”, “ที่”, “ของ”, “is”, “the”) คำ IDF จะต่ำมากจนใกล้ 0
 - แต่ถ้าคำนั้นเป็นคำเฉพาะเจาะจงที่โหลมาแค่เอกสารไม่กี่ฉบับ (เช่น “วัคซีน”, “بيتكوين”, “ปัญญาประดิษฐ์”) คำ IDF จะสูงมาก

- เมื่อจับมารวมกัน: **TF-IDF = TF × IDF**



ค่า TF-IDF สูง

หมายความว่า คำนั้นปรากฏบ่อยในเอกสารฉบับนี้ และไม่ค่อยปรากฏในเอกสารฉบับอื่น (เป็นคำที่เป็นเอกลักษณ์หรือเป็นคีย์เวิร์ดของเอกสารนี้จริง ๆ)

ค่า TF-IDF ต่ำ

หมายความว่า คำนั้นอาจจะแทบไม่ปรากฏเลย หรือเป็นคำโหล ๆ ที่มีอยู่ทั่วไปในทุกเอกสาร จึงไม่มีคุณค่าในการนำมาคิดแยก

2. ประโยชน์ของ TF-IDF



Search Engine (ระบบค้นหาข้อมูล)

ช่วยให้ Google หรือระบบค้นหาในเว็บไซต์ของคุณ ดึงบทความที่ตรงกับ “คีย์เวิร์ด” ที่ผู้ใช้ค้นหามากที่สุดขึ้นมาแสดง โดยคัดคำเชื่อมทั่วไปออกไป



Keyword Extraction (การดึงคำสำคัญ)

สรุปหา “คำค้นหลัก” หรือแท็ก (Tags) จากบทความขนาดยาวโดยอัตโนมัติ



Document Clustering / Classification (การจัดกลุ่มเอกสาร)

ช่วยแปลงข้อเสนอแนะ บทความ หรืออีเมลให้กลายเป็นตัวเลข เพื่อให้ AI สามารถแยกแยะได้ว่าอันไหนคือ อีเมลสแปม ข่าวการเมือง หรือข่าวกีฬา



Text Mining (การทำเหมืองข้อความ)

ใช้หาความสัมพันธ์ของคำในข้อมูลรีวิวนสินค้า หรือความคิดเห็นของลูกค้า



TF-IDF คือเครื่องมือพื้นฐานที่ทรงพลัง ช่วยให้คอมพิวเตอร์เข้าใจว่า “คำไหนสำคัญจริง” ในเอกสารจำนวนมาก